

# 基于BP神经网络和模糊推理系统的短时交通流预测

熊伟晴<sup>1</sup>, 燕晓波<sup>2</sup>, 姜守旭<sup>1</sup>, 李治军<sup>1</sup>

(1 哈尔滨工业大学 计算机科学与技术学院, 哈尔滨 150001; 2 吉林大学 计算机科学与技术学院, 长春 130012)

**摘 要:** 本文研究短时交通流预测。短时交通流预测是智能交通系统研究和实践的必要基础。本文提出和建立了一个短时交通流量预测模型, 该模型利用一个基于规则的模糊系统, 非线性地组合 BP 神经网络模型和自适应卡尔曼滤波模型的交通流量预测结果, 使得短时交通流量的预测结果更加准确可靠。该模型将传统方法和人工智能方法有机结合, 一方面, 利用神经网络强大的动态非线性映射能力, 从而提高预测精度; 另一方面, 充分发挥卡尔曼滤波的静态线性稳定性, 解决了单独使用 BP 神经网络进行预测时识别率不理想和可信度不高的问题。实验结果表明, 本文提出的短时交通流预测模型具有较高的准确度和可靠性。

**关键词:** 短时交通流预测; BP 神经网络; 模糊推理系统; 卡尔曼滤波

中图分类号: TP39

文献标识码: A

文章编号: 2095-2163(2015)02-0043-05

## Short-term Traffic Flow Prediction based on BP Neural Network and Fuzzy Inference System

XIONG Weiqing<sup>1</sup>, YAN Xiaobo<sup>2</sup>, JIANG Shouxu<sup>1</sup>, LI Zhijun<sup>1</sup>

(1 School of Computer Science and Technology, Harbin Institute of Technology, Harbin 150001, China;

2 College of Computer Science and Technology, Jilin University, Changchun 130012, China)

**Abstract:** For the research and practice of modern intelligent transportation systems, short-term traffic flow prediction is an essential element. The main content of this paper is to establish a traffic prediction model for short-term traffic flow forecasting, using a rule-based fuzzy system, nonlinearly combine traffic flow forecasts resulting from an adaptive Kalman filter (KF) and BP neural network model, which is referred as KBF model. Organic combination of traditional methods and artificial intelligence methods, on one hand, makes use of the powerful dynamic nonlinear mapping ability of artificial neural network, so as to improve the prediction accuracy; On the other hand, takes full advantages of the static linear stability of the Kalman filter to solve the problem that the forecasts recognition rate is not satisfactory and the credibility is not high while using a BP neural network only. Verified by experiments, this model is useful for traffic flow forecasting with high accuracy and high reliability.

**Key words:** Short-term Traffic Flow Prediction; BP Neural Network; Fuzzy Inference System; Kalman Filter

## 0 引言

随着经济的快速发展, 现代化进程的不断推进, 私人汽车大规模普及, 致使城市交通压力日渐增加, 交通拥堵、交通安全以及由交通引发的环境污染、能源紧缺等问题也随之加重与突出, 相当程度上影响了人民群众的日常生活和城市的上限发展, 因而引起了社会各界的广泛关注。当前, 交通问题在各国都是一个亟待解决的热点和焦点问题。作为目前公认的全面有效地解决交通问题的最佳途径, 智能交通系统(Intelligent Transportation System, ITS)已然赢得了研究者的瞩目与青睐, 成为抢眼的研究亮点。所谓智能交通系统<sup>[1]</sup>是将先进的信息技术、数据通讯技术、电子技术、传感器技术以及计算机处理技术等综合起来, 用于整个交通运输体系, 从而在大范围内建立一种可全方位发挥作用的实时、准确、高效的交通综合管理系统。

智能交通系统若想发挥预期的理想作用, 必须首先获得及时、准确的交通流量信息, 才能对道路网进行协调以使其得到最大限度的利用, 如此才能为出行者选择方便快捷可行的路径。获得的交通流量信息将不可避免地存在一定的延迟, 对当前时刻的交通状况也就必然难以做到实时呈现, 因此, 准确、可靠的交通流量预测即可为智能交通系统提供精准、有效的交通流量预测值, 并用于道路交通状况的动态管理。综上所述, 短时交通流预测已经成为现代智能交通系统研究和实践的必要基础, 对其展开研究则具有重要的现实意义和实用价值。本文提出了一个短时交通流量预测模型, 该模型利用一个基于规则的模糊系统, 非线性地组合来自 BP 神经网络模型和自适应卡尔曼滤波模型的交通流量预测结果, 使得短时交通流量的预测结果更加准确可靠。在本文中, 将这种组合模型称之为 KBF 模型(Combination of Kal-

收稿日期: 2015-03-16

基金项目: 国家自然科学基金(61370214, 60803148)。

作者简介: 熊伟晴(1990-), 女, 江西宜春人, 硕士研究生, 主要研究方向: 数据挖掘、时空轨迹数据;

燕晓波(1986-), 男, 河南郑州人, 硕士研究生, 主要研究方向: 物联网、大数据、机器学习等;

姜守旭(1968-), 男, 黑龙江哈尔滨人, 博士, 教授, 博士生导师, 主要研究方向: 普适计算、无线传感器网络、手机感知网络等;

李治军(1977-), 男, 内蒙古伊盟人, 博士, 副教授, 硕士生导师, 主要研究方向: 普适计算、P2P 网络、操作系统等。

man Filter and BP Neural Network with a Rule – based Fuzzy System)。

## 1 相关工作

1977年,Box和Jenkins提出创立了ARIMA – 自回归移动平均模型(又被称为Box – Jenkins模型)<sup>[2]</sup>。1979年Ahmed和Cook将时间序列模型应用于交通流预测领域<sup>[3]</sup>。1981年Stephanedes提出了历史平均模型<sup>[4]</sup>。1984年Iwao Okutani利用卡尔曼滤波理论建立交通流量预测模型<sup>[5]</sup>。Vythoulkas也提出了基于卡尔曼滤波理论的交通流量预测模型<sup>[6]</sup>。1992年,人工神经网络被Chin用于长期交通预测。1993年Kim和Hobeika又把ARIMA模型应用到高速公路道路交通流量预测领域<sup>[7]</sup>。1994年Hobeika, A. G和Chang Kyun Kim提出了根据截面历史数据、实时数据和上游交通数据进行短时交通流预测<sup>[8]</sup>。1997年Brian L. Smith和Mieheal J. Demetsky中对历史平均模型、时间序列模型、神经网络模型和非参数回归模型进行了比较,结果非参数回归模型以其参数简单、精度高成为了小样本预测中最佳的预测模型<sup>[9]</sup>。2002年, Sherif Ishak和Haitham Al – Deek对几种短时交通流预测模型进行了应用、分析和比较<sup>[10]</sup>。

我国智能交通的建设相比于国外发达国家来说开始得较晚,在短时交通流量预测方面也要晚一点。从90年代起,国内一些研究机构和学者开始着手交通流量预测方面的研究。1998年朱中和杨兆升提出了利用神经网络预测交通量的方法<sup>[11]</sup>。1999年杨兆升在文献[12]中提出了基于卡尔曼滤波技术的交通流量预测方法。2000年吉林工业大学初连禹和杨兆升等人提出了一种基于模糊神经网络的交通流量预测模型<sup>[13]</sup>。孙喜梅提出了交通预测信息的组合预测方法<sup>[14]</sup>。尹宏宾、徐建闽、黄什进等人提出了基于遗传神经网络的道路交通量预测模型<sup>[15]</sup>。

## 2 KBF模型设计

### 2.1 KBF模型框架

KBF模型是利用基于规则的模糊推理系统,非线性的组合Kalman滤波和BP神经网络的预测结果,具体的模型框架如图1所示。

首先,用Kalman滤波和BP神经网络预测出 $k$ 时刻的值,分别用其产生的值与 $k$ 时刻的实际观测值进行比较,哪一方的预测值最接近实际观测值,预测 $k+1$ 时刻的交通流量时就将其作为第一个输入,否则即作为第二个输入。这主要与模糊推理系统的IF – THEN规则有关,在IF – THEN规则中,第一个输入对结果的影响要比第二个输入对结果的影响更大。哪一方的预测值更接近实际观测值,就说明这一方更值得信赖,自然对下一次预测的影响相应地更大。

### 2.2 KBF模型设计

根据2.1节的理论分析,对KBF模型的设计如下:

- (1) BP神经网络的训练。
- (2) 利用Kalman滤波和BP神经网络分别预测 $k$ 时刻的交通流量。
- (3) 根据 $k-1$ 时刻的选择,将Kalman滤波和神经网络预测值作为模糊推理系统的输入,得到 $k$ 时刻最终的预测值。

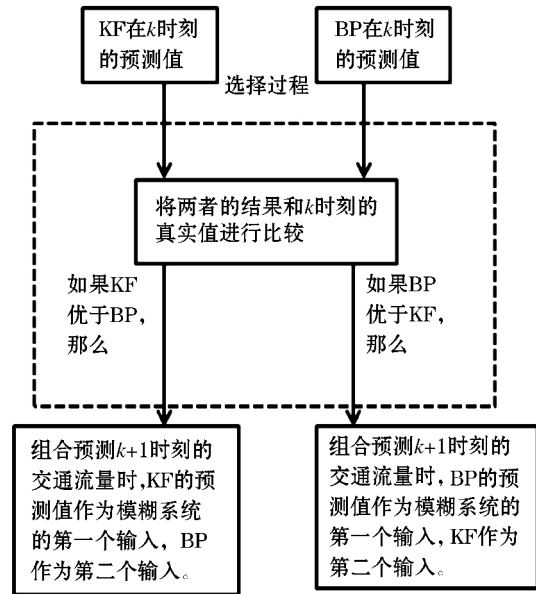


图1 KBF模型框架

Fig. 1 Framework of KBF model

(4) 为下一次预测做出选择,如果没有结束,跳至(3)继续执行。

(5) 预测停止。

KBF模型的流程图如图2所示。

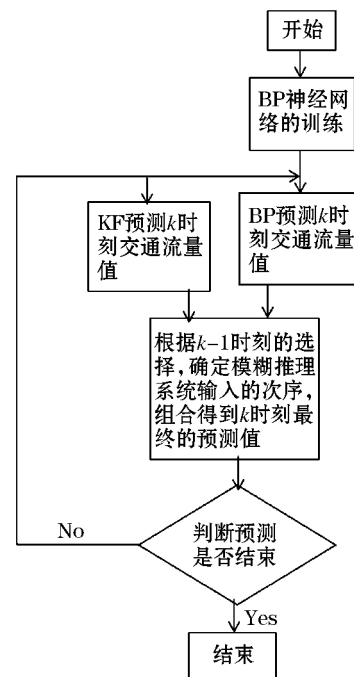


图2 KBF模型流程图

Fig. 2 Flow diagram of KBF model

### 2.3 KBF模型预测交通流量的实现

本文以图3所示的城市路网中典型的相邻路口为研究背景。在图3中,A与B代表两个十字路口, $q_1(k)$ 、 $q_2(k)$ 、 $q_3(k)$ 和 $q(k)$ 表示 $((k-1)T, kT]$ 时间间隔内的交通流数值,交通流方向为图中所示的方向。在本文中, $T$ 表示设定的时间间隔, $k$ 表示从1开始的连续正整数。

经分析, 短时交通流量数值不仅具有时间上的相关性, 也具有空间的相关性。即  $q(k+1)$  既与本处前  $m$  个时间间隔的交通流量数值相关, 也与图中其它三处前  $m$  个时间间隔的交通流量数值相关。一般  $m$  取 3, 即:

$$q(k+1) = f(L(k), L(k-1), L(k-2)) \quad (1)$$

式中  $L(k) = [q_1(k), q_2(k), q_3(k), q(k)]^T$  为非线性函数。




图3 相邻路口流量

Fig. 3 Traffic flow of adjacent intersection

### 2.3.1 Kalman 滤波用于交通流量预测

Kalman 滤波用于交通流量预测如下所示, 式(1)所描述的交通流量预测模型可以简化为:

$$q_{KF}(k+1) = A_0(k)V(k) + A_1(k)V(k-1) + A_2(k)V(k-2) + \mu(k) \quad (2)$$

式中  $A_0(k)$ 、 $A_1(k)$ 、 $A_2(k)$  为  $1 \times 4$  维状态变量向量;  $\mu(k)$  为观测噪声, 假定为零均值的白噪声, 方差为  $R(k)$ 。  $V(k)$  的定义为:

$$V(k) = [q_1(k), q_2(k), q_3(k), q(k)]^T \quad (3)$$

为了更利于应用 Kalman 滤波理论, 可作如下变换:

$$\begin{cases} H(k) = [V^T(k), V^T(k-1), V^T(k-2)] \\ X(k) = [A_0(k), A_1(k), A_2(k)]^T \\ Z(k) = q_{KF}(k+1) \end{cases} \quad (4)$$

可得:

$$\begin{cases} X(k) = \Phi(k)X(k-1) + \omega(k-1) \\ Z(k) = H(k)X(k) + \mu(k) \end{cases} \quad (5)$$

式中  $Z(k)$  为观测变量;  $X(k)$  为状态向量;  $H(k)$  为观测向量;  $\Phi(k)$  为状态转移矩阵, 且  $\Phi(k) = I$ ;  $\omega(k-1)$  为模型噪声, 假定为零均值的白噪声, 其协方差矩阵为  $Q(k-1)$ 。

根据 Kalman 滤波理论, 可得如下方程组:

$$\begin{cases} P(k|k-1) = \Phi(k-1) \times P(k-1) \times \Phi^T(k-1) + Q(k-1) \\ K(k) = P(k|k-1) \times H^T(k) \times [H(k) \times P(k|k-1) \times H^T(k) + R(k)]^{-1} \\ \bar{X}(k|k-1) = \Phi(k) \times \bar{X}(k-1) \\ \bar{X}(k) = \bar{X}(k|k-1) + K(k) \times [Z(k) - H(k) \times \bar{X}(k|k-1)] \\ P(k) = [I - K(k) \times H(k)] \times P(k|k-1) \\ P(0|0) = P(0) \\ \bar{X} = \bar{X}(0|1) + K(0) \times [Z(0) - H(0) \times \bar{X}(0|1)] \end{cases} \quad (6)$$

式中  $K_k$  为卡尔曼增益;  $P_k$  为滤波误差方差阵。  $R(k)$ ,

$Q(k-1)$  和  $P(0)$  设为对角阵,  $\bar{X}(0|1)$  设为零向量。

当  $\bar{X}(k)$  确定后, 可得交通流量预测值为:

$$q_{KF}(k+1) = H(k) \times \bar{X}(k) \quad (7)$$

### 2.3.2 BP 神经网络用于交通流量预测

本文中采用的是一个四层的四输入单输出的 BP 神经网络, 即具有两个隐含层, 第一个隐含层的神经元个数为 30, 第二个隐含层神经元个数为 10。

### 2.3.3 模糊推理系统

本文采用是一个两输入单输出的模糊推理系统。模糊推理系统的组成如下:

(1) 隶属度函数。本文将交通流量分为六个模糊集, 分别为 VS(very small)、RS(relative small)、S(small)、B(big)、RB(relative big) 和 VB(very big), 因此本文共有 18 个隶属度函数, 其中两输入和一个输出隶属于同一个模糊集的程度相同。下面仅列出一个输入的 6 个不同的隶属度函数:

$$\begin{aligned} \mu_{VS}(x) &= \begin{cases} 0 & x \leq -16 \\ \frac{x+16}{12}, & -16 \leq x \leq -4 \\ 1, & -4 \leq x \leq 4 \\ \frac{16-x}{12}, & 4 \leq x \leq 16 \\ 0 & x \geq 16 \end{cases} & \mu_{RS}(x) &= \begin{cases} 0 & x \leq 4 \\ \frac{x-4}{16}, & 4 \leq x \leq 20 \\ \frac{36-x}{16}, & 20 \leq x \leq 36 \\ 0 & x \geq 36 \end{cases} \\ \mu_S(x) &= \begin{cases} 0 & x \leq 20 \\ \frac{x-20}{16}, & 20 \leq x \leq 36 \\ \frac{48-x}{16}, & 36 \leq x \leq 48 \\ 0 & x \geq 48 \end{cases} & \mu_B(x) &= \begin{cases} 0 & x \leq 36 \\ \frac{x-36}{12}, & 36 \leq x \leq 48 \\ \frac{64-x}{48}, & 48 \leq x \leq 64 \\ 0 & x \geq 64 \end{cases} \\ \mu_{RB}(x) &= \begin{cases} 0 & x \leq 48 \\ \frac{x-48}{16}, & 48 \leq x \leq 64 \\ \frac{76-x}{12}, & 64 \leq x \leq 76 \\ 0 & x \geq 76 \end{cases} & \mu_{VB}(x) &= \begin{cases} 0 & x \leq 64 \\ \frac{x-64}{14}, & 64 \leq x \leq 78 \\ 1, & 78 \leq x \leq 106 \\ \frac{150-x}{44}, & 106 \leq x \leq 150 \\ 0 & x \geq 150 \end{cases} \end{aligned}$$

(2) IF-THEN 规则。本文采用的 36 条 IF-THEN 规则如表 1 表示。

表 1 KBF 模型中采用的 IF-THEN 规则

Tab. 1 36 If-then rules in KBF model

	VS	RS	S	B	RB	VB
VS	VS	RS	RS	RS	RS	RS
RS	RS	RS	RS	RS	RS	RS
S	RS	S	S	S	S	S
B	B	B	B	B	B	B
RB	RB	RB	S	B	RB	RB
VB	VB	VB	S	B	VB	VB

## 3 实验

### 3.1 实验数据

本文的实验数据是使用 SUMO(Simulation of Urban Mobility) 仿真平台模拟的数据。SUMO 仿真平台是一个开源的, 高度可移植的, 微观的和连续的道路交通仿真包。图 4 为 SUMO 模拟的交通路网。




图4 SUMO 模拟的交通路网

Fig. 4 A traffic network simulated by SUMO

本次仿真中,以5min为一个时间段统计交通流量,仿真了将近48个小时,得到连续的550条数据。实验数据中 $q_1$ 为这条道路向东行驶的车流, $q_2$ 为这条道路向右拐的车流, $q_3$ 为该道路向左拐的车流, $q_4$ 为该道路向东行驶的车流。

对于Kalman滤波和模糊推理,数据可以不进行归一化,而使用源数据。对于BP神经网络,如果不进行归一化,可能出现奇异矩阵的情况,导致训练提前终止,所以有必要对数据进行归一化处理。

### 3.2 实验结果评价指标

设 $X_p(k)$ 为使用交通流量模型得到的预测值, $X_t(k)$ 为实际仿真的交通流量值, $n$ 为样本总数。本文采用以下四个评价指标<sup>[16]</sup>,具体的计算方法如下所示:

预测准确率: 预测准确率 =

$$\frac{(x_p(k) - x_t(k)) \text{ 和绝对值小于 } 0.5 \text{ 的 } x_p(k) \text{ 的个数}}{n} \quad (8)$$

百分比平均相对误差  $E_{PMR}$ :

$$E_{PMR} = \frac{1}{n} \sum_{k=1}^n \frac{|x_p(k) - x_t(k)|}{x_t(k)} \times 100\% \quad (9)$$

均方根相对误差  $E_{RR}$ :

$$E_{RR} = \sqrt{\frac{1}{n} \sum_{k=1}^n \left( \frac{x_p(k) - x_t(k)}{x_t(k)} \right)^2} \quad (10)$$

均等系数  $C_E$ :

$$C_E = 1 - \frac{\sqrt{\sum_{k=1}^n (x_p(k) - x_t(k))^2}}{\sqrt{\sum_{k=1}^n (x_p(k))^2} + \sqrt{\sum_{k=1}^n (x_t(k))^2}} \quad (11)$$

### 3.3 实验结果及分析评价

图5为分别使用KF、BP和KBF预测模型得到的预测值

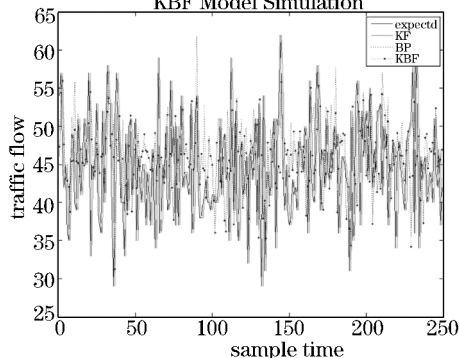


图5 短时交通流预测模型预测值与期望值的对比曲线

Fig. 5 Comparison between the predicted value and the observed value

和期望值(即实际观测值)的对比曲线;表2列出了KF、BP和KBF预测模型的评价指标值,包括:预测准确率 $E_{PMR}$ ,  $E_{RR}$ ,  $C_E$ 。

表2 短时交通流预测模型预测结果对比

Tab. 2 Comparison of experimental results

误差指标	KF Model	BP Model	KBF Model
预测准确率	0.670 7	0.726 9	0.747 0
$E_{PMR}$	0.026 5	0.068 0	0.051 9
$E_{RR}$	8.736 4	9.925 2	8.513 0
$C_E$	0.901 4	0.914 5	0.916 1

从图5和表2可知:

(1) KF、BP和KBF短时交通流预测模型都能很好地给出目标时间间隔的交通流量,均具有较小的预测误差。

(2) 作为短时交通流预测模型评价指标,预测准确率是最重要的一个评价指标。在表2中,可以看出,KBF短时交通流预测模型预测准确率最高。这说明KBF短时交通流预测模型有很高的预测准确度。

(3) 由表2可以看出,KBF、KF和BP预测模型的均等系数都超过了0.9,而且KBF预测模型表现最优。

(4) 在表2中,就 $E_{PMR}$ 评价指标而言,KBF预测模型远优于KF模型,接近BP模型。就 $E_{RR}$ 评价指标而言,KBF、KF和BP预测模型表现相近。

由实验结果及相关评价指标可得出结论:本文提出的KBF模型可以对短时交通流量进行较准确的预测,总体来说,预测效果优于单项预测模型(即卡尔曼滤波模型、BP神经网络模型),可以应用于实际交通工程。

### 4 结束语

本文在分析当前短时交通流预测模型的基础上,提出和建立了KBF模型,该模型利用模糊推理系统来组合Kalman滤波和BP神经网络的预测结果,从而获得最终的交通流量预测值。KBF模型组合了Kalman滤波、BP神经网络和模糊推理系统,发挥三种模型的优势,减弱单一模型的局限性,从而提高了短时交通流预测的准确度和稳定性。利用SUMO模拟得到的数据,对KBF模型进行了测试,实验结果表明,KBF模型的综合性能要优于单一的Kalman滤波和BP神经网络模型,可以应用于实际交通工程。

### 参考文献:

- [1] Ichiro Masaki. A brief History of ITS [R]. USA: Massachusetts Institute of Technology, 1999.
- [2] Box G E P, Jenkins G M. Time series analysis: forecasting and control [R]. San Francisco: holder Day, 1977.
- [3] AHMED S A, COOK A R. Analysis of freeway traffic time-series data by using Box-Jenkins technique [J]. Transportation Research Record 722, 1979: 1-9.
- [4] STEPHANEDES Y J, MICHALOPOULOS P G, PLUM R A. Improved estimation of traffic flow for real-time control [J]. Transportation Research Record, 1981, 795: 28-29.

(下转第51页)

统 Ubuntu 12.04。

表3 虚拟机配置不同

Tab. 3 Different virtual machines configuration

虚拟用户数	虚拟机实例	响应时间	请求成功率
50	Small	2 236	100%
	Medium	2 012	100%
	Large	1 862	100%
150	Small	3 762	95.8%
	Medium	2 976	97%
	Large	2 578	99.7%
300	Small	6 292	52%
	Medium	5 372	84%
	Large	4 823	96.9%
500	Small	18 876	32%
	Medium	11 778	54%
	Large	7 836	87.2%

实验一结果表明,在测试环境配置和负载数量都相同的情况下,传统测试环境和云测试平台具有相一致的性能测试结果,这间接验证了将软件的性能测试活动迁移到云计算环境下的可行性。实验二结果表明,在云测试环境下,随着虚拟机实例的配置越高,其生成负载的质量越好,而对应的性能测试结果就越可靠。

## 5 结束语

本文结合云计算和自动化性能测试技术,解决了在传统测试环境下,性能测试环境构建困难、测试资源不足等难题,设计并实现了云环境下性能测试平台的原型系统。通过该云测试平台,测试用户只需要通过提交测试环境资源描述文件和测试脚本,云平台即可进行测试资源的动态分配,测试环境的自动配置,并把测试任务分配到各虚拟机实例上执行,最后将测试结果集中展现给用户。实验结果表明,云环境下的性能测试,有助于用户节省巨大的测试成本,且能明

显优化用户的测试工作,并可获得与传统测试环境下的性能测试相一致的测试结果。

在实验过程中,却仍存在测试虚拟机运行效率不高,虚拟机调度算法适应性不强等问题。若能研发更好的调度算法,则将在更大程度上展现云环境下性能测试的优势。

## 参考文献:

- [1] NIST, NIST. The NIST definition of Cloud Computing [J]. Communications of the ACM, 2010, 53(6): 50-50.
- [2] PARVEEN T, TILLEY S. When to migrate software testing to the Cloud? [J]. Software Testing, Verification, and Validation Workshops, Third International Conference on, 2010: 424-427.
- [3] RIUNGU L M, TAIPALE O, SMOLANDER K. Software testing as an online service: Observations from practice [C]//Software Testing, Verification, and Validation Workshops (ICSTW), 2010 Third International Conference on, [S.l.]: IEEE, 2010: 418-423.
- [4] CIORTEAL, ZAMFCC, BUCURS, et al. Cloud9: a software testing service [J]. IEEE Trans on Operating Systems Review, 2009, 43(4): 5-10.
- [5] TAKAYUKI B, HITOSHI K, RYOK, et al. D-cloud: design of a software testing environment for reliable distributed systems using cloud computing technology [C]//Proc of the 10<sup>th</sup> International Conference on Cluster, Cloud and Grid Computing, Washington DC: IEEE Computer Society, 2010: 631-636.
- [6] HANAWAT, BANZAIT, KOIZUMIH, et al. Large-scale software testing environment using cloud computing technology for dependable parallel and distributed systems [C]//Proc of the 3<sup>rd</sup> International Conference on Software Testing, Verification and Validation, Washington DC: IEEE Computer Society, 2010: 428-433.
- [7] PARVEEN T, TILLEY S, DALEY N, et al. Towards a distributed execution framework for JUnit test cases [C]//Software Maintenance, Icsm, IEEE International Conference on, [S.l.]: IEEE, 2009: 425-428.
- [8] GANON Z, ZILBERSHTEIN I E. Cloud-based performance testing of network management Systems [C]//Computer Aided Modeling and Design of Communication Links and Networks, 2009. CAMAD 09. IEEE 14<sup>th</sup> International Workshop on, [S.l.]: IEEE, 2009: 1-6.
- [9] OKUTANI I. Dynamic prediction of traffic volume through kalman filtering theory [J]. Transportation Research, 1984: 1-11.
- [10] Vythoulkas P C. Alternative Approaches to Short Term Traffic Forecasting for Use in Driver Information Systems. Transportation and Traffic Theory [M]. Amsterdam: Elsevier Science Publishers, 1993: 458-505.
- [11] 王进, 史其信. 短时交通流预测模型综述 [J]. ITS 通讯, 2005, 7(1): 10-13.
- [12] HOBEIKA A G, KIM C K. Traffic-flow-prediction systems based on upstream traffic [C]//Vehicle Navigation and Information Systems Conference 1994, Yokohama: IEEE, 1994: 345-350.
- [13] SMITH B L, DEMESKY M J. Traffic flow forecasting: comparison of modeling approaches [J]. Journal of Transportation Engineering, 1997, 123(4): 261-266.
- [14] ISHAK S, AL-DEEK H. Performance evaluation of short-term time-series traffic prediction model [J]. Journal of Transportation Engineering, 2002, 28(6): 490-498.
- [15] 朱中, 杨兆升. 实时交通流量人工神经网络预测模型 [J]. 中国公路学报, 1998(4): 89-92.
- [16] 杨兆升, 朱中. 基于卡尔曼滤波理论的交通流量实时预测模型 [J]. 中国公路学报, 1999, 12(3): 63-67.
- [17] 初连禹, 杨兆升. 基于模糊神经网络的实时路段行程时间估计 [J]. 系统工程理论与实践, 2000, 11(11): 111-116.
- [18] 孙喜梅. 交通信息的组合预测方法 [D]. 长春: 吉林大学, 2003.
- [19] 尹宏宾, 徐建闽, 黄什进. 基于模糊神经网络的信号交叉口交通量预测 [J]. 华南理工大学学报, 2000(6): 11-15.
- [20] 沈国江, 王啸虎, 孔祥杰. 短时交通流量智能组合模型及应用 [J]. 系统工程理论与实践, 2011, 31(3): 561-568.

(上接第46页)